

# Zaznavanje fermentacijske aktivnosti z zvokom

Yon Ploj

**Povzetek**—V članku predstavimo metodo zaznavanja fermentacijske aktivnosti piva z analizo zvoka mehurčkov, ki nastajajo pri izhajanju ogljikovega diksida iz vrelne posode. S posnetki zvokov mehurčkov smo naučili model, ki razlikuje mehurčke od ambientnega šuma. Model smo implementirali na mikrokrmlilniku, tako da za detektor ne potrebujemo dodatne strojne opreme, kot je strežnik.

## I. UVOD

Fermentacija ali alkoholno vrenje je osrednji biokemijski proces pri proizvodnji piva. Hitrost fermentacije odraža metabolno aktivnost kvasa v trenutnih okoljskih pogojih, zato ocenjevanje fermentacijske aktivnosti predstavlja nepogrešljivo povratno informacijo o zdravju kvasa, kar neposredno vpliva na kakovost piva.

Avtomatska ocena hitrosti fermentacije omogoča zgodnje odkrivanje odstopanj od optimalnih pogojev in pravočasno prilaganje. Avtomatizacija nam omogoča nenehno merjenje, s čimer prispevamo k večji procesni stabilnosti in s tem boljšim in ponovljivejšim senzoričnim lastnostim piva.

Industrijski respirometri ponavadi delujejo na principu volumetrične analize izhajajočega ogljikovega dioksida, zaradi česar potrebujejo natančne in drage merilne inštrumente. Brez njih se zanašamo na ocenjevanje ‐po posluhu‐, torej vsake toliko časa poslušamo nastajanje mehurčkov v sifonu vrelnega zapaha (ang. *airlock*).

V tem članku predstavimo pristop zaznavanja fermentacijske aktivnosti piva z analizo zvoka mehurčkov, kar omogoča neinvazivno in avtomatizirano spremljanje fermentacije.

## II. METODE

Našo eksperimentalno postavitev obsega 30-litrska neprodušno zaprta (razen sifona) fermentacijska posoda, v njenem pokrovu pa sifon, ki omogoča izhajanje plinov, ko v posodi naraste tlak. Na pokrovu posode se nahaja mikrokrmlilnik ESP-32D z mikrofonom INMP441, ki komunicira z računalnikom prek brezžičnega interneta.

### A. Zajem podatkov

V prvem delu smo iz mikrokrmlnika zbirali surove zvočne posnetke. Zbrali smo posnetke v različnih reprezentativnih okoliščinah, ki jih pričakujemo v praksi. Ker se fermentor nahaja v bivalnem prostoru, pričakujemo šume, kot so pogovor, smrčanje, zvok televizije, ipd.

Z websocket povezavo smo uspeli v realnem času pošiljati zvok na strežnik, ki je posnetek shranil v datoteko oblike wav.

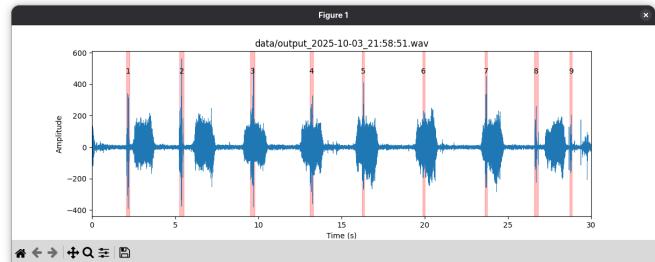
### B. Označevanje

Posnetke smo opremili z oznakami s pomočjo odprtakodnega programa Label Studio. Zvoke mehurčkov smo označili kot časovne intervale na posnetku.

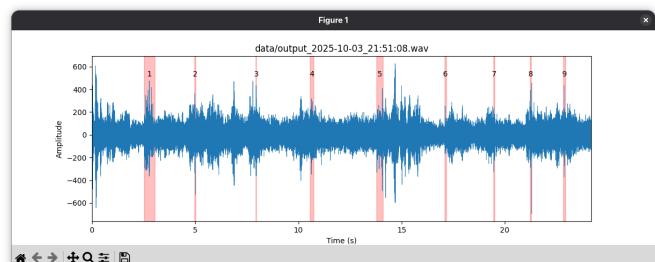
Slika 2 prikazuje primer zvočnega posnetka z označenimi mehurčki, v katerem je v ozadju slišno ritmično smrčanje. Slika 3 prikazuje težavnejši primer posnetka, v katerem je v ozadju prisoten pogovor in zvok televizije.



Slika 1. Airlock



Slika 2. Primer anotacij na posnetku s smrčanjem



Slika 3. Primer anotacij na posnetku z močnim šumom

Zaradi težavnosti označevanja smo obseg podatkov močno omejili. Kljub veliki količini posnetega materiala, smo zbrali le 130 označenih intervalov na skupnem obsegu 256 sekund posnetka.

### C. Gradnja detektorja

S programskim jezikom Python smo zgradili orodje, ki omogoča testiranje in evalvacijo različnih detektorjev in metod predprocesiranja.

1) *Vzorčenje:* Iz zvočnih posnetkov smo vzorčili okna v širini 0.10 sekunde. Vzorčili smo le okna, ki so bodisi popolnoma vsebovana v označbi mehurčka, bodisi z njimi nimajo preseka. Poskrbeli smo tudi, da se pari vzorcev med sabo niso prekrivali, saj bi s tem lahko učni podatki ušli v testne.

Vzorčili smo kar se da mnogo pozitivnih vzorcev, dokler je bilo to še mogoče brez prekrivanja. Zaradi stohastične narave vzorčenja število vzorcev ni bilo konstantno, temveč se je gibalo med 150 in 165. Pri negativnih vzorcih ni bilo omejitve, a smo jih vedno zajeli le toliko, kolikor je bilo pozitivnih. V nasprotnem primeru smo sicer opazili, da so se nekateri klasifikatorji naučili le prevladujočega razreda.

2) *Algoritmi:* Implementirali smo metodo podpornih vektorjev, naključni gozd in logistično regresijo.

Podatke smo predpripravili bodisi z identitetno funkcijo (brez predprocesiranja), s kratko-časovno Fourierjevo transformacijo, z zvezno ali z diskretno valčno transformacijo.

Algoritem smo nato 20-krat pognali čez vse kombinacije klasifikatorjev in predprocesorjev in zbrali povprečne F1 vrednosti. Rezultati so prikazani v tabeli I.

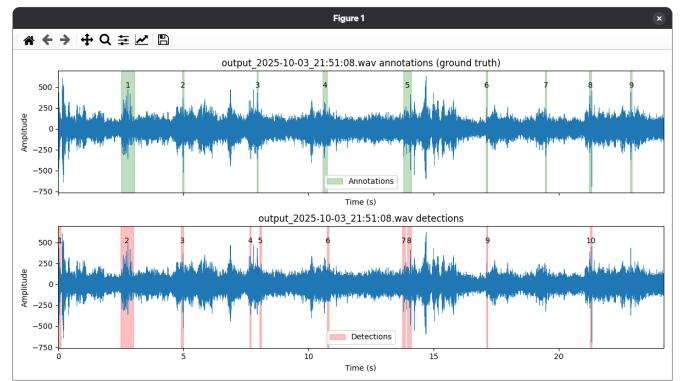
Analiza optimalnih parametrov za klasifikatorje je izpuščena iz tega članka. Ročno poiskani približki optimalnih parametrov so:

- Predprocesorji
  - Kratko-časovna Fourierjeva transformacija:  
dolžina analiznega okna: 2048 vzorcev, dolžina koraka: 512 vzorcev, okno: **hann**,
  - Diskretna valčna transformacija:  
val: **haar**
  - Zvezna valčna transformacija:  
val: **morl**
- Detektorji
  - Naključni gozd:  
število dreves: 100, maksimalna globina: 10
  - Logistična regresija:  
prag: 0.5
  - Podporni vektorji:  
regularizacijski parameter  $C$ : 1.0, jedro: **RBF**

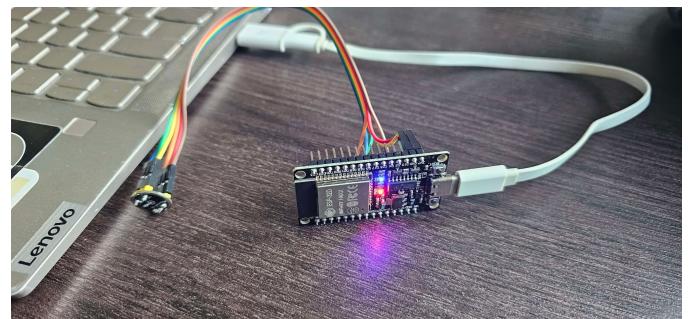
### D. Uporaba

Zmagovalni detektor smo implementirali v programskem jeziku Arduino in ga naložili na mikrokrmlnik na našem fermentoru. Ob zaznanem zvoku mehurčka zasveti z lučko in objavi sporočilo prek protokola MQTT. Ločena obveščevalna enota ta sporočila spremlja in nas potem lahko obvesti o nenavadnih vzorcih mehurčkov.

Ker je programski prostor na mikrokrmlniku strogo omejen, smo parametre modela kvantizirali na 16 bitov. Ker jezik Arduino ne podpira 16-bitnih števil s plavajočo vejico, smo števila v zapisu IEEE-754 interpretirali kot 16-bitno celo število `uint16_t`, ga v tej obliki naložili v program, nato pa med računanjem izvedli inverzno operacijo.



Slika 4. Rezultati detekcije na močno šumnem posnetku



Slika 5. Mikrokrmlnik ESP32 in mikrofon INMP441

## III. REZULTATI

Tabela I prikazuje glavne rezultate analize – F1 vrednosti različnih kombinacij detektorjev in predprocesorjev. Očitno je kombinacija podpornih vektorjev in kratkočasovne Fourierjeve transformacije najboljša.

Slika 4 prikazuje vizualen rezultat najboljšega detektorja. Vidimo, da kljub močnemu šumu dobro loči med zvokom mehurčka in človeškega glasu.

Tabela I  
POVPREČNE F1 VREDNOSTI ZA RAZLIČNE KOMBINACIJE  
PREDPROCESORJEV IN DETEKTORJEV (20 PONOVITEV)

Detektor	Identitetna	STFT	DWT	CWT
Naklj. gozd	0.790	0.866	0.488	0.639
MPV	0.736	0.891	0.364	0.329
Log. reg.	0.482	0.838	0.402	0.474
Linearna MPV	0.415	0.859	0.168	0.430

Praktični rezultati implementacije eksperimenta na mikrokrmlniku niso kvantitativni, a subjektivno bi delovanje opisal kot precej dobro, čeprav nekoliko slabše kot pričakovano iz laboratorijskih testov.

## IV. DISKUSIJA

Pri prenosu detektorja iz laboratorijskega okolja na mikrokrmlnik se je pokazalo več omejitve. Izračun STFT je računsko zahteven in ni izvedljiv v realnem času. Posledično zelo hitri mehurčki v nekaterih primerih niso bili zaznani, kar omejuje natančnost ocenjevanja visoke aktivnosti.

Kvantizacija parametrov modela na 16 bitov je povzročila opazno, čeprav zmerino poslabšanje delovanja, kar pa bi lahko rešili z dodatnim pomilnikom EEPROM na vodilu I<sup>2</sup>C.

Pomembna omejitev študije je tudi skromen nabor označenih podatkov. Zaradi zahtevnega ročnega dela smo bili prisiljeni v kompromis med količino in raznolikostjo podatkov, kar omejuje zanesljivost statistične evalvacije in splošnost rezultatov. Kljub temu so bili detektorji sposobni spodbognega nivoja generalizacije na reprezentativne vrste šuma našega okolja.

V prihodnje bi bilo smiselno raziskati lažje predprocesne metode ali detektorje, ki bi zahtevali manj računskih virov in omogočili višjo časovno ločljivost. Alternativno bi uporaba zmogljivejšega mikrokrmlnika ali namenskega DSP-ja omogočila ohranitev natančnosti tudi v vgrajenem sistemu. Prav tako bi večji podatkovni nabor omogočil uporabo sodobnejših metod strojnega učenja ter bolj zanesljivo evalvacijo.

#### V. ZAKLJUČEK

V tem delu smo predstavili neinvaziven pristop za zaznavanje fermentacijske aktivnosti piva z analizo zvoka mehurčkov v vrelni zapahi. Pokazali smo, da je mogoče z relativno preprostimi metodami strojnega učenja in ustreznim predprocesiranjem doseči detekcijo tudi v prisotnosti okoljskega šuma.

Eksperimentalni rezultati potrjujejo, da spektralni opis zvoka v kombinaciji s klasifikatorjem podpornih vektorjev omogoča zanesljivo razlikovanje med mehurčki in drugimi zvočnimi dogodki. Implementacija na mikrokrmlniku dokazuje praktično uporabnost pristopa, čeprav so računske in numerične omejitve vgrajenih sistemov pomemben dejavnik pri končni uspešnosti.

Predlagana metoda predstavlja cenovno ugodno alternativo klasičnim meritvam fermentacijske aktivnosti ter odpira možnosti za nenehno spremljanje procesa v domačih in manjših pivovarskih okoljih.